

- 贝叶斯判别根据概率判别规则，有：

若 $P(\omega_1 | x) > P(\omega_2 | x)$ ，则 $x \in \omega_1$

若 $P(\omega_1 | x) < P(\omega_2 | x)$ ，则 $x \in \omega_2$

由贝叶斯定理，后验概率 $P(\omega_i | x)$ 可由类别 ω_i 的先验概率 $P(\omega_i)$ 和 x 的条件概率密度 $p(x | \omega_i)$ 来计算，即：

$$P(\omega_i | x) = \frac{p(x | \omega_i)P(\omega_i)}{p(x)} = \frac{p(x | \omega_i)P(\omega_i)}{\sum_{i=1}^2 p(x | \omega_i)P(\omega_i)}$$

这里 $p(x | \omega_i)$ 也称为似然函数。将该式代入上述判别式，有：

若 $p(x | \omega_1)P(\omega_1) > p(x | \omega_2)P(\omega_2)$ ，

则 $x \in \omega_1$

若 $p(x | \omega_1)P(\omega_1) < p(x | \omega_2)P(\omega_2)$ ，

则 $x \in \omega_2$

或

若 $l_{12}(x) = \frac{p(x | \omega_1)}{p(x | \omega_2)} > \frac{P(\omega_2)}{P(\omega_1)}$ ，则 $x \in \omega_1$

若 $l_{12}(x) = \frac{p(x | \omega_1)}{p(x | \omega_2)} < \frac{P(\omega_2)}{P(\omega_1)}$ ，则 $x \in \omega_2$

其中， l_{12} 称为似然比， $P(\omega_2)/P(\omega_1)=\theta_{21}$ 称为似然比的判决阈值，此判别称为贝叶斯判别。

- 贝叶斯判别计算实例

已知： $P(\omega_1)=0.2$ ， $P(\omega_2)=0.8$ ，

$$p(x=\text{异常}|\omega_1)=0.6, \quad p(x=\text{正常}|\omega_1)=0.4,$$

$$p(x=\text{异常}|\omega_2)=0.1, \quad p(x=\text{正常}|\omega_2)=0.9$$

利用贝叶斯公式，有：

$$\begin{aligned} P(\omega_1|x=\text{异常}) &= \frac{p(x=\text{异常}|\omega_1)P(\omega_1)}{p(x=\text{异常})} \\ &= \frac{p(x=\text{异常}|\omega_1)P(\omega_1)}{p(x=\text{异常}|\omega_1)P(\omega_1) + p(x=\text{异常}|\omega_2)P(\omega_2)} \\ &= \frac{0.6 \times 0.2}{0.6 \times 0.2 + 0.1 \times 0.8} = 0.6 \end{aligned}$$

$$\text{似然比: } l_{12} = \frac{p(x=\text{异常}|\omega_1)}{p(x=\text{异常}|\omega_2)} = \frac{0.6}{0.1} = 6$$

$$\text{判决阈值: } \theta_{21} = \frac{P(\omega_2)}{P(\omega_1)} = \frac{0.8}{0.2} = 4$$

- 最小平均条件风险表达式

按贝叶斯公式，最小平均条件风险可写成：

$$r_j(x) = \frac{1}{p(x)} \sum_{i=1}^M L_{ij} p(x | \omega_i) P(\omega_i)$$

因 $1/p(x)$ 为公共项，可舍去，因此可简化为：

$$r_j(x) = \sum_{i=1}^M L_{ij} p(x | \omega_i) P(\omega_i)$$

这也是贝叶斯分类器，只是它的判别方法不是按错误概率最小作为标准，而是按平均条件风险作为标准。

● 两类（M=2）情况的贝叶斯最小风险判别

选 M=2，即全部的模式样本只有 ω_1 和 ω_2 两类，要求分类器将模式样本分到 ω_1 和 ω_2 两类中，则平均风险可写成：

当分类器将 x 判别为 ω_1 时：

$$r_1(x) = L_{11}p(x | \omega_1)P(\omega_1) + L_{21}p(x | \omega_2)P(\omega_2)$$

当分类器将 x 判别为 ω_2 时：

$$r_2(x) = L_{12}p(x | \omega_1)P(\omega_1) + L_{22}p(x | \omega_2)P(\omega_2)$$

若 $r_1(x) < r_2(x)$ ，则 x 被判定为属于 ω_1 ，此时：

$$\begin{aligned} L_{11}p(x | \omega_1)P(\omega_1) + L_{21}p(x | \omega_2)P(\omega_2) < \\ L_{12}p(x | \omega_1)P(\omega_1) + L_{22}p(x | \omega_2)P(\omega_2) \end{aligned}$$

即

$$(L_{21} - L_{22})p(x | \omega_2)P(\omega_2) < (L_{12} - L_{11})p(x | \omega_1)P(\omega_1)$$

通常取 $L_{ij} > L_{ii}$ ，有：

$$\text{当 } \frac{p(x | \omega_1)}{p(x | \omega_2)} > \frac{P(\omega_2)}{P(\omega_1)} \cdot \frac{L_{21} - L_{22}}{L_{12} - L_{11}} \text{ 时, } x \in \omega_1$$

$$\text{该式左边为似然比: } l_{12} = \frac{p(x | \omega_1)}{p(x | \omega_2)}$$

$$\text{右边为阈值: } \theta_{21} = \frac{P(\omega_2)}{P(\omega_1)} \cdot \frac{L_{21} - L_{22}}{L_{12} - L_{11}}$$


故得两类模式的贝叶斯判别条件为：

- (1) 若 $l_{12}(x) > \theta_{21}$ ，则 $x \in \omega_1$
- (2) 若 $l_{12}(x) < \theta_{21}$ ，则 $x \in \omega_2$
- (3) 若 $l_{12}(x) = \theta_{21}$ ，则可做任意判别。

通常，当判别正确时，不失分，可选常数 $L_{11}=L_{22}=0$ ；判别错误时，

可选 $L_{12}=L_{21}=1$ ，此时 $\theta_{21} = \frac{P(\omega_2)}{P(\omega_1)}$ 。

- 两类（M=2）情况的贝叶斯最小风险判别实例



如图所示为一信号通过一受噪声干扰的信道。

信道输入信号为 0 或 1，噪声为高斯型，其均值 $\mu=0$ ，方差为 σ^2 。

信道输出为 x ，试求最优的判别规则，以区分 x 是 0 还是 1。

设送 0 为 ω_1 类，送 1 为 ω_2 类，从观察值 x 的基础上判别它是 0 还是 1。直观上可以看出，若 $x < 0.5$ 应判为 0， $x > 0.5$ 应判为 1。用贝叶斯判别条件分析：设信号送 0 的先验概率为 $P(0)$ ，送 1 的先验概率为 $P(1)$ ， L 的取值为：

$$L = \begin{matrix} & \begin{matrix} a_1 & a_2 \end{matrix} \\ \begin{matrix} \omega_1 \\ \omega_2 \end{matrix} & \begin{pmatrix} 0 & L_{12} \\ L_{21} & 0 \end{pmatrix} \end{matrix}$$

这里 a_1 和 a_2 分别对应于输入状态为 0 和 1 时的正确判别， L_{12} 对应于实际上是 ω_1 类但被判成 ω_2 类(a_2)时的代价， L_{21} 对应于实际上是 ω_2 类但被判成 ω_1 类(a_1)时的代价。正确判别时 L 取 0。

当输入信号为 0 时，受噪声为正态分布 $N(0, \sigma^2)$ 的干扰，其幅值大小的概率密度为：

$$p(x | \omega_1) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{x^2}{2\sigma^2}}$$

当输入信号为 1 时: $p(x|\omega_2) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-1)^2}{2\sigma^2}}$

则似然比为: $l_{12} = \frac{p(x|\omega_1)}{p(x|\omega_2)} = e^{\frac{1-2x}{2\sigma^2}}$

若 $l_{12} > \theta_{21}$, 即 $e^{\frac{1-2x}{2\sigma^2}} > \theta_{21} \Rightarrow x < \frac{1}{2} - \sigma^2 \ln \theta_{21}$, 则 $x \in \omega_1$, 此时信号应是 0, 即

$$x < \frac{1}{2} - \sigma^2 \ln \left(\frac{L_{21}}{L_{12}} \cdot \frac{P(1)}{P(0)} \right)$$

若取 $L_{21}=L_{12}=1$, $P(1)=P(0)$, 则 $x < 1/2$ 判为 0。

若无噪声干扰, 即 $\sigma^2=0$, 则 $x < 1/2$ 判为 0。

- 多类（M 类）情况的贝叶斯最小风险判别

对于 M 类情况，若 $r_i(x) < r_j(x)$, $j = 1, 2, \dots, M, j \neq i$, 则 $x \in \omega_i$ 。

L 可如下取值（仍按判对失分为 0，判错失分为 1 记）：

$$L_{ij} = \begin{cases} 0 & \text{when } i = j \\ 1 & \text{when } i \neq j \end{cases}$$

则条件平均风险可写成：

$$\begin{aligned} r_j(x) &= \sum_{i=1}^M L_{ij} p(x|\omega_i) P(\omega_i) \\ &= L_{1j} p(x|\omega_1) P(\omega_1) + \dots + L_{jj} p(x|\omega_j) P(\omega_j) + \dots + L_{Mj} p(x|\omega_M) P(\omega_M) \\ &= \sum_{i=1}^M p(x|\omega_i) P(\omega_i) - p(x|\omega_j) P(\omega_j) \\ &= p(x) - p(x|\omega_j) P(\omega_j) \end{aligned}$$

由 $r_i(x) < r_j(x)$ ，有当 $p(x|\omega_i) P(\omega_i) > p(x|\omega_j) P(\omega_j)$ 时， $x \in \omega_i$ ，对应

于判别函数为：取 $d_i(x) = p(x|\omega_i) P(\omega_i)$, $i = 1, 2, \dots, M$ ，则对于全部

$j \neq i$ 的值，若 $d_i(x) > d_j(x)$ ，则 $x \in \omega_i$ 。

- M 种模式类别的多变量正态类密度函数

具有 M 种模式类别的多变量正态类密度函数为：

$$p(x|\omega_i) = \frac{1}{(2\pi)^{n/2}|C_i|^{1/2}} \exp\left\{-\frac{1}{2}(x - m_i)^T C_i^{-1}(x - m_i)\right\},$$

$$i = 1, 2, \dots, M$$

其中，每一类模式的分布密度都完全被其均值向量 m_i 和协方差矩阵 C_i 所规定，其定义为：

$$m_i = E_i\{x\}$$

$$C_i = E_i\{(x - m_i)(x - m_i)^T\}$$

$E_i\{x\}$ 表示对类别属于 ω_i 的模型的数学期望。

在上述公式中， n 为模式向量的维数， $|C_i|$ 为矩阵 C_i 的行列式，协方差矩阵 C_i 是对称的正定矩阵，其对角线上的元素 C_{kk} 是模式向量第 k 个元素的方差，非对角线上的元素 C_{jk} 是 x 的第 j 个分量 x_j 和第 k 个分量 x_k 的协方差。当 x_j 和 x_k 统计独立时， $C_{jk}=0$ 。当协方差矩阵的全部非对角线上的元素都为零时，多变量正态类密度函数可简化为 n 个单变量正态类密度函数的乘积。

已知类别 ω_i 的判别函数可写成如下形式：

$$d_i(x) = p(x|\omega_i)P(\omega_i), i = 1, 2, \dots, M$$

对于正态密度函数，可取自然对数的形式以方便计算（因为自然对数是单调递增的，取对数后不影响相应的分类性能），则有：

$$d_i(x) = \ln[p(x|\omega_i)] + \ln P(\omega_i), i = 1, 2, \dots, M$$

代入正态类密度函数，有：

$$d_i(x) = \ln P(\omega_i) - \frac{n}{2} \ln(2\pi) - \frac{1}{2} \ln |C_i| - \frac{1}{2} (x - m_i)^T C_i^{-1} (x - m_i), \quad i = 1, 2, \dots, M$$

去掉与 i 无关的项（并不影响分类结果），有：

$$d_i(x) = \ln P(\omega_i) - \frac{1}{2} \ln |C_i| - \frac{1}{2} (x - m_i)^T C_i^{-1} (x - m_i), \quad i = 1, 2, \dots, M$$

即为正态分布模式的贝叶斯判别函数。

● 两类问题且其类模式都是正态分布的情况

(1) 当 $C_1 \neq C_2$ 时, 两类模式的正态分布为: $p(x|\omega_1)$ 表示为 $N(m_1, C_1)$,

$p(x|\omega_2)$ 表示为 $N(m_2, C_2)$, ω_1 和 ω_2 两类的判别函数对应为:

$$d_1(x) = \ln P(\omega_1) - \frac{1}{2} \ln |C_1| - \frac{1}{2} (x - m_1)^T C_1^{-1} (x - m_1)$$

$$d_2(x) = \ln P(\omega_2) - \frac{1}{2} \ln |C_2| - \frac{1}{2} (x - m_2)^T C_2^{-1} (x - m_2)$$

$$d_1(x) - d_2(x) = \begin{cases} > 0 & x \in \omega_1 \\ < 0 & x \in \omega_2 \end{cases}$$

(2) 当 $C_1 = C_2 = C$ 时, 有:

$$d_i(x) = \ln P(\omega_i) - \frac{1}{2} \ln |C| - \frac{1}{2} x^T C^{-1} x + \frac{1}{2} x^T C^{-1} m_i + \frac{1}{2} m_i^T C^{-1} x - \frac{1}{2} m_i^T C^{-1} m_i, i = 1, 2$$

因 C 为对称矩阵, 上式可简化为:


$$d_i(x) = \ln P(\omega_i) - \frac{1}{2} \ln |C| - \frac{1}{2} x^T C^{-1} x + m_i^T C^{-1} x - \frac{1}{2} m_i^T C^{-1} m_i, i = 1, 2$$

由此可导出类别 ω_1 和 ω_2 间的判别界面为:

$$d_1(x) - d_2(x) = \ln P(\omega_1) - \ln P(\omega_2) + (m_1 - m_2)^T C^{-1} x - \frac{1}{2} m_1^T C^{-1} m_1 + \frac{1}{2} m_2^T C^{-1} m_2 = 0$$

- 两类问题且其类模式都是正态分布的实例

$P(\omega_1)=P(\omega_2)=1/2$ ，求其判别界面。



模式的均值向量 m_i 和协方差矩阵 C_i 可用下式估计：

$$m_i = \frac{1}{N_i} \sum_{j=1}^{N_i} x_{ij} \quad i=1,2$$

$$C_i = \frac{1}{N_i} \sum_{j=1}^{N_i} (x_{ij} - m_i)(x_{ij} - m_i)^T \quad i=1,2$$

其中 N_i 为类别 ω_i 中模式的数目， x_{ij} 代表在第 i 个类别中的第 j 个模

式。由上式可求出：

$$m_1 = \frac{1}{4}(3 \ 1 \ 1)^T$$

$$m_2 = \frac{1}{4}(1 \ 3 \ 3)^T$$

$$C_1 = C_2 = C = \frac{1}{16} \begin{pmatrix} 3 & 1 & 1 \\ 1 & 3 & -1 \\ 1 & -1 & 3 \end{pmatrix}, \quad C^{-1} = 4 \begin{pmatrix} 2 & -1 & -1 \\ -1 & 2 & 1 \\ -1 & 1 & 2 \end{pmatrix}$$

设 $P(\omega_1)=P(\omega_2)=1/2$ ，因 $C_1=C_2$ ，则判别界面为：

$$\begin{aligned}
d_1(x) - d_2(x) &= (m_1 - m_2)^T C^{-1} x - \frac{1}{2} m_1^T C^{-1} m_1 + \frac{1}{2} m_2^T C^{-1} m_2 \\
&= 8x_1 - 8x_2 - 8x_3 + 4 = 0
\end{aligned}$$

● 均值和协方差矩阵的估计量定义

设模式的类概率密度函数为 $p(\mathbf{x})$ ，则其均值向量定义为：

$$\mathbf{m} = E(\mathbf{x}) = \int_{\mathbf{x}} \mathbf{x}p(\mathbf{x})d\mathbf{x}$$

其中， $\mathbf{x} = (x_1, x_2, \dots, x_n)^T$ ， $\mathbf{m} = (m_1, m_2, \dots, m_n)^T$ 。

若以样本的平均值作为均值向量的近似值，则均值估计量 $\hat{\mathbf{m}}$ 为：

$$\hat{\mathbf{m}} = \frac{1}{N} \sum_{j=1}^N \mathbf{x}_j$$

其中 N 为样本的数目。

协方差矩阵为：

$$\mathbf{C} = \begin{pmatrix} c_{11} & c_{12} & \cdots & c_{1n} \\ c_{21} & c_{22} & \cdots & c_{2n} \\ \vdots & \vdots & & \vdots \\ c_{n1} & c_{n2} & \cdots & c_{nn} \end{pmatrix}$$

其每个元素 c_{lk} 定义为：

$$\begin{aligned} c_{lk} &= E\{(x_l - m_l)(x_k - m_k)\} \\ &= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} (x_l - m_l)(x_k - m_k)p(x_l, x_k)dx_l dx_k \end{aligned}$$

其中， x_l 、 x_k 和 m_l 、 m_k 分别为 \mathbf{x} 和 \mathbf{m} 的第 l 和 k 个分量。

协方差矩阵写成向量形式为：

$$\mathbf{C} = E\{(\mathbf{x} - \mathbf{m})(\mathbf{x} - \mathbf{m})^T\} = E\{\mathbf{x}\mathbf{x}^T\} - \mathbf{m}\mathbf{m}^T$$

协方差矩阵的估计量（当 $N \gg 1$ 时）为：

$$\hat{\mathbf{C}} \approx \frac{1}{N} \sum_{k=1}^N (\mathbf{x}_k - \hat{\mathbf{m}})(\mathbf{x}_k - \hat{\mathbf{m}})^T$$

这里，样本模式总体为 $\{ \mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_k, \dots, \mathbf{x}_N \}$ 。因为计算估计量时没有真实的均值向量 \mathbf{m} 可用，只能用均值向量的估计量 $\hat{\mathbf{m}}$ 来代替，会存在偏差。

● 均值和协方差矩阵估计量的迭代运算形式

假设已经计算了 N 个样本的均值估计量，若再加上一个样本，其新的估计量 $\hat{m}(N+1)$ 为：

$$\hat{m}(N+1) = \frac{1}{N+1} \sum_{j=1}^{N+1} x_j = \frac{1}{N+1} \left[\sum_{j=1}^N x_j + x_{N+1} \right] = \frac{1}{N+1} [N\hat{m}(N) + x_{N+1}]$$

其中 $\hat{m}(N)$ 为从 N 个样本计算得到的估计量。迭代的第一步应取 $\hat{m}(1) = x_1$ 。

协方差矩阵估计量的迭代运算与上述相似。取 $\hat{C}(N)$ 表示 N 个样本时的估计量为：

$$\hat{C}(N) = \frac{1}{N} \sum_{j=1}^N x_j x_j^T - \hat{m}(N) \hat{m}^T(N)$$

加入一个样本，则：

$$\begin{aligned} \hat{C}(N+1) &= \frac{1}{N+1} \sum_{j=1}^{N+1} x_j x_j^T - \hat{m}(N+1) \hat{m}^T(N+1) \\ &= \frac{1}{N+1} \left[\sum_{j=1}^N x_j x_j^T + x_{N+1} x_{N+1}^T \right] - \hat{m}(N+1) \hat{m}^T(N+1) \\ &= \frac{1}{N+1} [N\hat{C}(N) + N\hat{m}(N) \hat{m}^T(N) + x_{N+1} x_{N+1}^T] - \\ &\quad \frac{1}{(N+1)^2} [N\hat{m}(N) + x_{N+1}] [N\hat{m}(N) + x_{N+1}]^T \end{aligned}$$

其中， $\hat{C}(1) = x_1 x_1^T - \hat{m}(1) \hat{m}^T(1)$ 且 $\hat{m}(1) = x_1$ ，因此 $\hat{C}(1) = 0$ 为零矩阵。

● 一般概念

设 $\{x_1, x_2, \dots, x_N\}$ 为 N 个用于估计一未知参数 θ 的密度函数的样本， x_i 被一个接着一个逐次地给出。于是用贝叶斯定理，可以得到在给定 x_1, x_2, \dots, x_N 之后， θ 的后验概率密度的迭代表示式为：

$$p(\theta|x_1, \dots, x_N) = \frac{p(x_N|\theta, x_1, \dots, x_{N-1})p(\theta|x_1, \dots, x_{N-1})}{p(x_N|x_1, \dots, x_{N-1})}$$

其中，对于 $p(\theta | x_1, \dots, x_N)$ 而言， $p(\theta | x_1, \dots, x_{N-1})$ 是它的先验概率，当加入新的样本 x_N 后，得到经过修正的新的概率密度 $p(\theta | x_1, \dots, x_N)$ 。如此一步步向前推，则 $p(\theta)$ 应为最初先验概率密度，当读入第一个样本 x_1 时，经过贝叶斯定理计算，可得到后验概率密度 $p(\theta | x_1)$ 。以此为新的第一步，将 $p(\theta | x_1)$ 作为第二步计算的先验概率密度，读入样本 x_2 ，又得到第二步的后验概率密度 $p(\theta | x_1, x_2)$ ，...，依此可以算出最后的后验概率密度 $p(\theta | x_1, \dots, x_N)$ ，从而得到最终的结果。

这里，需要先知道最初先验概率密度函数 $p(\theta)$ 。至于全概率 $p(x_N | x_1, \dots, x_{N-1})$ 则可通过下式算出：

$$p(x_N|x_1, \dots, x_{N-1}) = \int_x p(x_N|\theta, x_1, \dots, x_{N-1}) p(\theta|x_1, \dots, x_{N-1}) d\theta$$

该值与未知量 θ 无关，可认为是一定值。

- 单变量正态密度函数的均值学习

设一个模式样本集，其类概率密度函数是单变量正态分布 $N(\theta, \sigma^2)$ ，均值 θ 待求，即

$$p(x|\theta) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left[-\frac{1}{2}\left(\frac{x-\theta}{\sigma}\right)^2\right]$$

给出 N 个训练样本 $\{x_1, x_2, \dots, x_N\}$ ，用贝叶斯学习计算其均值估计量。

设最初的先验概率密度 $p(\theta)$ 为 $N(\theta_0, \sigma_0^2)$ ，这里 θ_0 是凭先验知识对未知量 θ 的“最好”推测， σ_0^2 表示上述推测的不确定性度量。这里可以假定 $p(\theta)$ 是正态的，因为均值的估计量是样本的线性函数，因样本 x 是正态分布的，因此 $p(\theta)$ 取为正态分布是合理的，这样计算起来可比较简单。

初始条件已知，即 $p(\theta)$ 为 $N(\theta_0, \sigma_0^2)$ ， $p(x_1|\theta)$ 为 $N(\theta, \sigma^2)$ ，由贝叶斯公式 $p(\theta|x_1) = a p(x_1|\theta) p(\theta)$ ，可得：

$$p(\theta|x_1) = a \cdot \frac{1}{\sqrt{2\pi}\sigma} \exp\left[-\frac{1}{2}\left(\frac{x_1-\theta}{\sigma}\right)^2\right] \cdot \frac{1}{\sqrt{2\pi}\sigma_0} \exp\left[-\frac{1}{2}\left(\frac{\theta-\theta_0}{\sigma_0}\right)^2\right]$$

其中 a 是一定值。由贝叶斯法则有：

$$p(\theta|x_1, \dots, x_N) = \frac{p(x_1, \dots, x_N|\theta)p(\theta)}{\int_{\Phi} p(x_1, \dots, x_N|\theta)p(\theta)d\theta}$$

这里 Φ 表示整个模式空间。由于每一次迭代是从样本子集中逐个抽取一个变量，所以 N 次运算是独立地抽取 N 个变量，因此上式可写成：

$$p(\theta|x_1, \dots, x_N) = a \left\{ \prod_{k=1}^N p(x_k|\theta) \right\} p(\theta)$$

代入 $p(x_k|\theta)$ 和 $p(\theta)$ 的值，得：

$$p(\theta|x_1, \dots, x_N)$$

$$\begin{aligned} &= a \left\{ \prod_{k=1}^N \frac{1}{\sqrt{2\pi}\sigma} \exp \left[-\frac{1}{2} \left(\frac{x_k - \theta}{\sigma} \right)^2 \right] \right\} \\ &\quad \cdot \frac{1}{\sqrt{2\pi}\sigma_0} \exp \left[-\frac{1}{2} \left(\frac{\theta - \theta_0}{\sigma_0} \right)^2 \right] \\ &= a' \exp \left[-\frac{1}{2} \left\{ \sum_{k=1}^N \left(\frac{x_k - \theta}{\sigma} \right)^2 \right\} + \left(\frac{\theta - \theta_0}{\sigma_0} \right)^2 \right] \\ &= a'' \exp \left[-\frac{1}{2} \left\{ \left(\frac{N}{\sigma^2} + \frac{1}{\sigma_0^2} \right) \theta^2 - 2 \left(\frac{1}{\sigma^2} \sum_{k=1}^N x_k + \frac{\theta_0}{\sigma_0^2} \right) \theta \right\} \right] \end{aligned}$$

上式每一步中与 θ 无关的项都并入常数项 a' 和 a'' ，这样 $p(\theta | x_1, \dots, x_N)$ 是 θ 平方函数的指数集合，仍是一正态密度函数。将它写成 $N(\theta_N, \sigma_N^2)$ 的形式，即：

$$\begin{aligned} p(\theta|x_1, \dots, x_N) &= \frac{1}{\sqrt{2\pi}\sigma_N} \exp \left[-\frac{1}{2} \left(\frac{\theta - \theta_N}{\sigma_N} \right)^2 \right] \\ &= a''' \exp \left[-\frac{1}{2} \left(\frac{\theta^2}{\sigma_N^2} - 2 \frac{\theta_N \theta}{\sigma_N^2} \right) \right] \end{aligned}$$

将上述两式相比较，得：

$$\begin{aligned} \frac{1}{\sigma_N^2} &= \frac{N}{\sigma^2} + \frac{1}{\sigma_0^2} \\ \frac{\theta_N}{\sigma_N^2} &= \frac{1}{\sigma^2} \sum_{k=1}^N x_k + \frac{\theta_0}{\sigma_0^2} = \frac{N}{\sigma^2} \hat{m}_N + \frac{\theta_0}{\sigma_0^2} \end{aligned}$$

解出 θ_N 和 σ_N ，得：

$$\begin{aligned} \theta_N &= \frac{N\sigma_0^2}{N\sigma_0^2 + \sigma^2} \hat{m}_N + \frac{\sigma^2}{N\sigma_0^2 + \sigma^2} \theta_0 \\ \sigma_N^2 &= \frac{\sigma_0^2 \sigma^2}{N\sigma_0^2 + \sigma^2} \end{aligned}$$

即根据对训练样本集 $\{x_i\}_{i=1,2,\dots,N}$ 的观察，求得均值 θ 的后验概率密度 $p(\theta | x_i)$ 为 $N(\theta_N, \sigma_N^2)$ ，其中 θ_N 是经过 N 个样本观察之后对均值的最好估计，它是先验信息（即 θ_0 ， σ_0^2 和 σ^2 ）与训练样本所给信息（即 N 和 \hat{m}_N ）适当结合的结果，是用 N 个训练样本对均值的先验估计 θ_0 的补充； σ_N^2 是对这个估计的不确定性的度量，因 σ_N^2 随 N 的增加而减小，因此当 $N \rightarrow \infty$ 时， σ_N^2 趋于零。由于 θ_N 是 \hat{m}_N 和 θ_0 的线性组合，两者的系数都非负且其和为 1，因此只要 $\sigma_0 \neq 0$ ，当 $N \rightarrow \infty$ 时， θ_N 趋于样本均值的估计量 \hat{m}_N 。

图中所示为一正态密度的均值学习过程，每增加一次对样本的预测，都可减小对 θ 估计的不确定性，所以 $p(\theta | x_1, \dots, x_N)$ 变得越来越峰形突起，且其均值与估计量 \hat{m}_N 之间的偏差的绝对值亦越来越小。

