

- 点到点之间的距离

在 n 维空间中， a 与 b 两点之间的欧氏距离为：

$$D(a, b) = \| a - b \|$$

写成距离平方：

$$D^2(a, b) = (a - b)^T (a - b) = \sum_{k=1}^n (a_k - b_k)^2$$

其中， a 和 b 为 n 维向量，其第 k 个分量分别是 a_k 和 b_k 。

- 点到点集之间的距离

在 n 维空间中，点 x 到点 $a^{(i)}$ 之间的距离平方为：

$$D^2(x, a^{(i)}) = \sum_{k=1}^n (x_k - a_k^{(i)})^2$$

因此，点 x 到点集 $\{a^{(i)}\}_{i=1, 2, \dots, K}$ 之间的均方距离为：

$$\overline{D^2(x, \{a^{(i)}\})} = \frac{1}{K} \sum_{i=1}^K D^2(x, a^{(i)}) = \frac{1}{K} \sum_{i=1}^K \left\{ \sum_{k=1}^n (x_k - a_k^{(i)})^2 \right\}$$

- 类内距离

n 维空间中同一类内各模式样本点集 $\{a^{(i)}\}_{i=1, 2, \dots, K}$ ，其内部各点的均方距离为 $\overline{D^2(\{a^{(j)}\}, \{a^{(i)}\})}$ ，其中 $i, j = 1, 2, \dots, K, i \neq j$ ，即：

$$\overline{D^2(\{a^{(j)}\}, \{a^{(i)}\})} = \frac{1}{K} \sum_{j=1}^K \left[\frac{1}{K-1} \sum_{\substack{i=1 \\ i \neq j}}^K \sum_{k=1}^n (a_k^{(j)} - a_k^{(i)})^2 \right]$$

可证明：

$$\overline{D^2} = 2 \sum_{k=1}^n \sigma_k^2$$

其中 σ_k^2 为 $\{a^{(i)}\}$ 在第 k 个分量上的无偏方差，即：

$$\sigma_k^2 = \frac{1}{K-1} \sum_{i=1}^K (a_k^{(i)} - \overline{a_k})^2$$

其中 $\overline{a_k} = \frac{1}{K} \sum_{i=1}^K a_k^{(i)}$ 为 $\{a^{(i)}\}$ 在第 k 个分量方向上的均值。

[证明作为练习]

- 类内散布矩阵

考虑一类内模式点集 $\{\mathbf{a}^{(i)}\}_{i=1,2,\dots,K}$ ，其类内散布矩阵为：

$$\mathbf{S} = \sum_{i=1}^K \{(\mathbf{a}^{(i)} - \mathbf{m})(\mathbf{a}^{(i)} - \mathbf{m})^T\}$$

其中

$$\mathbf{m} = \frac{1}{K} \sum_{i=1}^K \mathbf{a}^{(i)}$$

对属于同一类的模式样本，类内散布矩阵表示各样本点围绕其均值周围的散布情况。

- 类间距离和类间散布矩阵

在考虑有两个以上的类别，如集合 $\{a^{(i)}\}$ 和 $\{b^{(j)}\}$ 时，类间距离对类别的可分性起着重要作用，此时应计算：

$$\overline{D^2(\{a^{(i)}\}, \{b^{(j)}\})}_{i=1,2,\dots,K_a; j=1,2,\dots,K_b}$$

为简化起见，常用两类样本各自质心间的距离作为类间距离，并假设两类样本出现的概率相等，则：

$$D^2 = \sum_{k=1}^n (m_{1_k} - m_{2_k})^2$$

其中 m_1 和 m_2 为两类模式样本集各自的均值向量， m_{1_k} 和 m_{2_k} 为 m_1 和 m_2 的第 k 个分量， n 为维数。

写成矩阵形式： $S_{b2} = (m_1 - m_2)(m_1 - m_2)^T$ 为两类模式的类间散布矩阵。

对三个以上的类别，类间散布矩阵常写成：

$$S_b = \sum_{i=1}^c P(\omega_i)(m_i - m_0)(m_i - m_0)^T$$

其中， m_0 为多类模式（如共有 c 类）分布的总体均值向量，即：

$$m_0 = E\{x\} = \sum_{i=1}^c P(\omega_i)m_i, \quad \forall \omega_i, i = 1, 2, \dots, c$$

- 多类模式集散布矩阵

多类情况的类内散布矩阵，可写成各类的类内散布矩阵的先验概率的加权和，即：

$$S_w = \sum_{i=1}^c P(\omega_i) E\{(x - m_i)(x - m_i)^T \mid \omega_i\} = \sum_{i=1}^c P(\omega_i) C_i$$

其中 C_i 是第 i 类的协方差矩阵。

有时，用多类模式总体分布的散布矩阵来反映其可分性，即：

$$S_t = E\{(x - m_0)(x - m_0)^T\}, \quad x \in \forall \omega_i, \quad i = 1, 2, \dots, c$$

其中， m_0 为多类模式分布的总体均值向量。

可以证明： $S_t = S_w + S_b$ ，即总体散布矩阵是各类类内散布矩阵与类间散布矩阵之和。

● 对于 ω_i 和 ω_j 两类训练样本的特征选择

例：对于 ω_i 和 ω_j 两类训练样本，假设其均值向量为 m_i 和 m_j ，其 k 维方向的分量为 m_{ik} 和 m_{jk} ，方差为 σ_{ik}^2 和 σ_{jk}^2 ，定义可分性准则函数：

$$G_k = \frac{(m_{ik} - m_{jk})^2}{\sigma_{ik}^2 + \sigma_{jk}^2}, \quad k = 1, 2, \dots, n$$

则 G_k 为正值。 G_k 值越大，表示测度值的第 k 个分量对分离 ω_i 和 ω_j 两类越有效。将 $\{G_k, k=1, 2, \dots, n\}$ 按大小排队，选出最大的 m 个对应的测度值作为分类特征，即达到特征选择的目的。

- 一般特征的散布矩阵准则

$$\text{类内: } S_w = \sum_{i=1}^c P(\omega_i) E\{(x - m_i)(x - m_i)^T \mid \omega_i\}$$

$$\text{类间: } S_b = \sum_{i=1}^c P(\omega_i)(m_i - m_0)(m_i - m_0)^T$$

直观上，类间离散度越大且类内离散度越小，则可分性越好。因此，可推导出散布矩阵准则采用如下形式：

$$\text{行列式形式: } J_1 = \det(S_w^{-1} S_b) = \prod_i \lambda_i$$

$$\text{迹形式: } J_2 = \text{tr}(S_w^{-1} S_b) = \sum_i \lambda_i$$

其中， λ_i 是矩阵 $S_w^{-1} S_b$ 的特征值。使 J_1 或 J_2 最大的子集可作为选择的分类特征。

- 离散的有限 K-L 展开式的形式

设一连续的随机实函数 $x(t)$, $T_1 \leq t \leq T_2$, 则 $x(t)$ 可用已知的正交函数集 $\{\phi_j(t), j=1, 2, \dots\}$ 的线性组合来展开, 即:

$$\begin{aligned} x(t) &= a_1\phi_1(t) + a_2\phi_2(t) + \dots + a_j\phi_j(t) + \dots \\ &= \sum_{j=1}^{\infty} a_j\phi_j(t), \quad T_1 \leq t \leq T_2 \end{aligned} \quad (1)$$

式中, a_j 为展开式的随机系数, $\phi_j(t)$ 为一连续的正交函数, 它应满足:

$$\int_{T_1}^{T_2} \phi_n(t) \tilde{\phi}_m(t) dt = \begin{cases} 1, & \text{if } m = n \\ 0 & \text{if } m \neq n \end{cases}$$

其中 $\tilde{\phi}_m(t)$ 为 $\phi_m(t)$ 的共轭复数式。

将上式写成离散的正交函数形式, 使连续随机函数 $x(t)$ 和连续正交函数 $\phi_j(t)$ 在区间 $T_1 \leq t \leq T_2$ 内被等间隔采样为 n 个离散点, 即:

$$x(t) \rightarrow \{x(1), x(2), \dots, x(n)\}$$

$$\phi_j(t) \rightarrow \{\phi_j(1), \phi_j(2), \dots, \phi_j(n)\}$$

写成向量形式:

$$x = (x(1), x(2), \dots, x(n))^T$$

$$\phi_j = (\phi_j(1), \phi_j(2), \dots, \phi_j(n))^T, \quad j = 1, 2, \dots, n$$

将式(1)取 n 项近似, 并写成离散展开式:

$$x = \sum_{j=1}^n a_j \phi_j = \Phi a, \quad T_1 \leq t \leq T_2 \quad (2)$$

其中， \mathbf{a} 为展开式中随机系数的向量形式，即：

$$\mathbf{a} = (a_1, a_2, \dots, a_j, \dots, a_n)^T$$

Φ 为 $n \times n$ 维矩阵，即：

$$\Phi = (\varphi_1, \varphi_2, \dots, \varphi_n) = \begin{bmatrix} \varphi_1(1) & \varphi_2(1) & \cdots & \varphi_n(1) \\ \varphi_1(2) & \varphi_2(2) & \cdots & \varphi_n(2) \\ \cdots & \cdots & \cdots & \cdots \\ \varphi_1(n) & \varphi_2(n) & \cdots & \varphi_n(n) \end{bmatrix}$$

其中，每一列为正交函数集中的一个函数，小括号内的序号为正交函数的采样点次序。因此， Φ 实质上是由 φ_j 向量组成的正交变换矩阵，它将 \mathbf{x} 变换成 \mathbf{a} 。

- 正交向量集 $\{\phi_j\}$ 的确定

设随机向量 x 的总体自相关矩阵为 $R = E\{xx^T\}$ 。由

$$x = \sum_{j=1}^n a_j \phi_j = \Phi a, \quad T_1 \leq t \leq T_2 \quad (1)$$

将 $x = \Phi a$ 代入 $R = E\{xx^T\}$ ，得：

$$R = E\{\Phi a a^T \Phi^T\} = \Phi (E\{a a^T\}) \Phi^T$$

要求系数向量 a 的各个不同分量应统计独立，即应使 $(a_1, a_2, \dots, a_j, \dots, a_n)$ 满足如下关系：

$$E(a_j a_k) = \begin{cases} \lambda_j & \text{if } j = k \\ 0 & \text{if } j \neq k \end{cases}$$

写成矩阵形式，应使： $E\{a a^T\} = D_\lambda$ ，其中 D_λ 为对角形矩阵，其互相关成分均为 0，即：

$$D_\lambda = \begin{bmatrix} \lambda_1 & 0 & \cdots & \cdots & 0 \\ 0 & \ddots & 0 & \cdots & 0 \\ 0 & & \lambda_j & & 0 \\ 0 & \cdots & 0 & \ddots & 0 \\ 0 & \cdots & \cdots & 0 & \lambda_n \end{bmatrix}$$

则：

$$R = \Phi D_\lambda \Phi^T$$

由于 Φ 中的各个向量 ϕ_j 都相互归一正交，故有：

$$R \Phi = \Phi D_\lambda \Phi^T \Phi = \Phi D_\lambda$$

其中， ϕ_j 向量对应为：

$$\mathbf{R} \phi_j = \lambda_j \phi_j$$

可以看出， λ_j 是 \mathbf{x} 的自相关矩阵 \mathbf{R} 的特征值， ϕ_j 是对应的特征向量。因为 \mathbf{R} 是实对称矩阵，其不同特征值对应的特征向量应正交，即：

$$\phi_j^T \phi_k = \begin{cases} 1 & \text{if } j=k \\ 0 & \text{if } j \neq k \end{cases}$$

由式(1)，K-L 展开式系数应为：

$$\mathbf{a} = \Phi^T \mathbf{x}$$

- K-L 展开式系数的计算步骤

K-L 展开式系数可如下求得：

1. 求随机向量 \mathbf{x} 的自相关矩阵： $\mathbf{R} = \mathbf{E}\{\mathbf{x}\mathbf{x}^T\}$
2. 求出矩阵 \mathbf{R} 的特征值 λ_j 和对应的特征向量 ϕ_j , $j = 1, 2, \dots, n$,
得矩阵：

$$\Phi = (\phi_1, \phi_2, \dots, \phi_n)$$

3. 计算展开式系数：

$$\mathbf{a} = \Phi^T \mathbf{x}$$

- 问题：选取变换矩阵 Φ ，使得降维后的新向量在最小均方差条件下接近原来的向量 \mathbf{x}

对于 $\mathbf{x} = \sum_{j=1}^n \mathbf{a}_j \phi_j$ ，现仅取 m 项，对略去的系数项用预先选定的常数

b 代替，此时对 \mathbf{x} 的估计值为：

$$\hat{\mathbf{x}} = \sum_{j=1}^m \mathbf{a}_j \phi_j + \sum_{j=m+1}^n b \phi_j$$

则产生的误差为：

$$\Delta \mathbf{x} = \mathbf{x} - \hat{\mathbf{x}} = \sum_{j=m+1}^n (\mathbf{a}_j - b) \phi_j$$

则 $\Delta \mathbf{x}$ 的均方误差为：

$$\overline{\varepsilon^2} = E\{\|\Delta \mathbf{x}\|^2\} = \sum_{j=m+1}^n \{E(\mathbf{a}_j - b)^2\}$$

要使 $\overline{\varepsilon^2}$ 最小，对 b 的选择应满足：

$$\frac{\partial}{\partial b} [E(\mathbf{a}_j - b)^2] = \frac{\partial}{\partial b} [E(\mathbf{a}_j^2 - 2\mathbf{a}_j b + b^2)] = -2[E(\mathbf{a}_j) - b] = 0$$

因此， $b = E[\mathbf{a}_j]$ ，即对省略掉的 \mathbf{a} 中的分量，应使用它们的数学期望来代替，此时的误差为：

$$\begin{aligned} \overline{\varepsilon^2} &= \sum_{j=m+1}^n E[(\mathbf{a}_j - E\{\mathbf{a}_j\})^2] = \sum_{j=m+1}^n \phi_j^T E[(\mathbf{x} - E\{\mathbf{x}\})(\mathbf{x} - E\{\mathbf{x}\})^T] \phi_j \\ &= \sum_{j=m+1}^n \phi_j^T \mathbf{C}_x \phi_j \end{aligned}$$

其中， \mathbf{C}_x 为 \mathbf{x} 的协方差矩阵

设 λ_j 为 \mathbf{C}_x 的第 j 个特征值， ϕ_j 是与 λ_j 对应的特征向量，则

$$\mathbf{C}_x \phi_j = \lambda_j \phi_j$$

由于

$$\phi_j^T \phi_j = 1$$

从而

$$\phi_j^T C_x \phi_j = \lambda_j$$


因此

$$\overline{\varepsilon^2} = \sum_{j=m+1}^n \phi_j^T C_x \phi_j = \sum_{j=m+1}^n \lambda_j$$

由此可以看出， λ_j 值越小，误差也越小。

● K-L 变换实例

给定两类模式，其分布如图所示，试用 K-L 变换实现一维的特征提取（假定两类模式出现的概率相等）。



$$m = \frac{1}{5} \sum_{j=1}^{N_1} x_{1j} + \frac{1}{5} \sum_{j=1}^{N_2} x_{2j} = 0$$

符合 K-L 变换进行特征压缩的最佳条件。

因 $P(\omega_1) = P(\omega_2) = 0.5$ ，故

$$R = \sum_{i=1}^2 P(\omega_i) E\{xx^T\} = \frac{1}{2} \left[\frac{1}{5} \sum_{j=1}^5 x_{1j} x_{1j}^T \right] + \frac{1}{2} \left[\frac{1}{5} \sum_{j=1}^5 x_{2j} x_{2j}^T \right] = \begin{pmatrix} 25.4 & 25.0 \\ 25.0 & 25.4 \end{pmatrix}$$

解特征值方程 $|R - \lambda I| = 0$ ，求 R 的特征值。

由 $(25.4 - \lambda)^2 - 25.0^2 = 0$ ，得特征值 $\lambda_1 = 50.4$ ， $\lambda_2 = 0.4$

其对应的特征向量可由 $R\Phi_i = \lambda_i\Phi_i$ 求得：

$$\Phi_1 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \quad \Phi_2 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ -1 \end{pmatrix}$$

选 λ_1 对应的变换向量作为变换矩阵，由 $y = \Phi^T x$ 得变换后的一维模式特征为：

$$\omega_1 : \left\{ -\frac{10}{\sqrt{2}}, -\frac{9}{\sqrt{2}}, -\frac{9}{\sqrt{2}}, -\frac{11}{\sqrt{2}}, -\frac{11}{\sqrt{2}} \right\} \quad \omega_2 : \left\{ \frac{10}{\sqrt{2}}, \frac{11}{\sqrt{2}}, \frac{11}{\sqrt{2}}, \frac{9}{\sqrt{2}}, \frac{9}{\sqrt{2}} \right\}$$